

OpenVLA Projector의 시각정보 전달 재고: 토큰 압축의 온디바이스 효율과 멀티스케일 정보 전달

Rethinking Visual Information Transfer in the OpenVLA Projector:
On-device Efficiency of Token Compression and Multi-scale Information Delivery

김찬형

요약

시각-언어-행동(VLA) 모델 OpenVLA는 시각 인코더의 토큰을 거대언어모델(LLM)로 옮기는 projector로 단순한 2계층 다층퍼셉트론(MLP)을 사용한다. 본 연구의 목표는 온디바이스 환경에서의 실행을 염두에 두고, 추론 효율과 정보 전달 양 측면에서 더 나은 projector 설계를 탐색하는 것이다. 먼저 토큰 압축(256→64)은 정확도를 유지한 채 추론 시간을 약 21% 단축하여 온디바이스 효율 측면에서 유효함을 확인하였다. 다음으로, 토큰끼리 정보를 섞는 공간 혼합 projector(Honeybee의 합성곱, 자기어텐션)가 더 우수하리라 기대하였으나, 실제로는 정확도 이득이 없었다. 그 원인은 256개 시각 토큰의 공간 통합을 이미 LLM의 자기어텐션이 수행하므로 projector에서 다시 섞는 것이 중복이기 때문이며, 학습 붕괴의 진짜 원인 또한 공간 정보 부족이 아니라 정규화(LayerNorm)의 부재였다. 이에 토큰을 섞는 대신 projector의 입력 자체를 바꾸는 새로운 방향을 제안한다. OpenVLA는 비전 트랜스포머(ViT)의 끝에서 두 번째 층만 LLM에 전달하므로, 버려진 층을 함께 전달하는 멀티스케일 projector를 구현하였다. 그 결과 LLM에 도달하는 공간 정보가 통계적으로 유의하게 증가하였다(토큰별 멀티스케일 +31%, $p=0.0018$, 7개 시드; 스케일 간 어텐션 +34%, $p=0.019$, 5개 시드, 모든 시드 양수). 나아가 추론 시 LLM 내부의 시각 토큰 간 어텐션을 차단하면 동결 MLP가 86% 붕괴하는 반면 혼합형 projector는 거의 영향을 받지 않아, 공간 혼합을 LLM이 수행한다는 점을 인과적으로 확인하였다. 이 추가 공간 정보는 공간이 중요한 상태에서 행동 오차를 4.8% 줄였으나($p=0.025$), 자명한 상태에서는 오차가 19% 증가하여($p=0.008$) 전체 평균으로는 두 효과가 상쇄되어 소폭 악화로 나타났다(약 5%, 유의하지 않음). 종합하면, projector 설계의 핵심은 토큰 혼합이 아니라 정규화·사전학습과 LLM에 전달되는 입력 특징에 있다.

키워드: OpenVLA, Vision-Language-Action, Projector, Token Compression, Multi-scale Features, LayerNorm

1. 서론

시각-언어-행동(Vision-Language-Action, VLA) 모델인 OpenVLA [1]는 로봇 카메라 영상과 자연어 지시를 입력받아 7차원 로봇 행동을 출력한다. 이 구조에서 시각 인코더가 만든 토큰을 LLM의 입력 공간으로 옮기는 다리 역할을 하는 부분이 projector이며, OpenVLA는 이를 토큰마다 독립적으로 적용되는 2계층 MLP로 구현한다. 이 단순한 설계에는 두 가지 직관적 한계가 제기된다. 첫째, projector가 256개 패치 토큰을 각각 따로 처리하므로 토큰 사이의 공간 관계가 반영되지 않는다. 둘째, 256개 토큰을 그대로 LLM에 넘기므로

추론 연산량이 크다.

본 연구의 목표는 온디바이스 실행을 염두에 두고 더 나은 projector를 설계하는 것이다.¹ 우리는 처음에 두 가지를 기대하였다. 시각 토큰을 압축하면 추론을 가볍게 하면서도 정확도를 유지할 수 있다는 것, 그리고 패치를 따로 전달하는 대신 패치 사이의 공간 관계를 섞어 전달하면 성능이 향상되리라는 것이다. 이를 확인하기 위해 OpenVLA의 projector만 교체한 여러 변형을 동일 조건에서 비교하고, 정확도를 좌우하는 교란 요인을 분리하는 통제 실험을 설계하였다.

그러나 실험은 두 번째 기대를 뒤집었다. 공간 혼합 projector는 더 우수하지 않았으며, 그 까닭은 256개 시각 토큰의 공간 통합을 이미 LLM이 수행하기 때문이었다. 이 발견은 연구를 새로운 방향으로 이끌었다. 토큰을 섞는 대신, projector의 입력 즉 LLM에 도달하는 ViT 특징 자체를 바꾸는 것이다. 이에 따라 본 연구는 세 가지 기여를 제시한다. 토큰 압축이 정확도를 유지한 채 온디바이스 추론을 가속함을 실증하고, projector 내부의 공간 혼합이 정확도에 기여하지 못하며 진짜 변수는 정규화와 사전학습임을 통제 실험으로 규명하며, 버려진 ViT 층을 함께 전달하는 멀티스케일 projector를 안정적으로 설계하여 LLM에 도달하는 공간 정보를 유의하게 증가시킴을 새로이 보인다.



그림 1. OpenVLA 추론 파이프라인. 시각 인코더가 생성한 256×2176 토큰을 projector가 256×4096으로 변환해 LLM에 전달한다. 본 연구의 대상은 가운데 projector이다.

2. 방법론

2.1 관련 연구와 차별점

OpenVLA는 Prismatic VLM [2] 구조 위에서 DINOv2 [5]와 SigLIP [6] 두 시각 인코더를 융합하고, LLaMA-2 기반 LLM을 사용한다. 멀티모달 LLM에서 projector 설계는 활발히 연구되어 왔으며, Honeybee [3]는 합성곱 기반의 지역성 보존 압축 projector를 제안하였고, LLaVA [4]는 오히려 단순 MLP projector가 충분함을 보였다. 본 연구는 새로운 projector 구조를 제안하기보다, OpenVLA의 projector만 통제하여 교체함으로써 공간 혼합·압축·사전학습의 효과를 분리하고, 행동 정확도뿐 아니라 LLM에 전달되는 정보량을 직접 측정한다는 점에서 차별된다. 표현에 담긴 정보의 선형 접근성은 선형 탐침 [9] 방식으로 측정한다.

¹코드, 실험 스크립트, 측정 결과(JSON)는 다음에서 공개한다: <https://github.com/kchsugo/openvla-projector-study>

2.2 Projector 변형과 통제 설계

비교 대상은 사전학습 정렬을 계승한 동결 MLP, 난수에서 학습한 MLP(이하 난수 MLP), Honeybee식 압축 projector(256→64), 토큰 간 자기어텐션 projector, 그리고 본 연구가 도입한 멀티스케일 projector이다. 토큰마다 독립적으로 적용되는 기본 MLP는 식 (1)과 같이 정의되며, 토큰 간 정보 교환이 없다.

$$\mathbf{z}_i = \mathbf{W}_2 \text{GELU}(\mathbf{W}_1 \mathbf{v}_i), \quad i = 1, \dots, 256. \quad (1)$$

보강형 projector는 사전학습 MLP를 그대로 둔 채 게이트 γ 로 추가 경로를 더하는 잔차 구조를 사용한다.

$$\text{out} = \text{base}(\mathbf{x}) + \gamma \cdot \text{Enhance}(\mathbf{x}), \quad \gamma_{\text{init}} = 0. \quad (2)$$

게이트 γ 를 0으로 초기화하면 학습 시작 시점에 원본 OpenVLA와 동일하므로 성능 하한이 보장된다. 다만 게이트와 보강 경로의 출력을 모두 0으로 초기화하면 식 (3)처럼 양쪽 기울기가 동시에 0이 되어 보강 경로가 영원히 학습되지 못하는 기울기 교착이 발생한다.

$$\frac{\partial L}{\partial \gamma} = 0 \quad (\because \text{Enhance}=0), \quad \frac{\partial L}{\partial \text{Enhance}} = 0 \quad (\because \gamma=0). \quad (3)$$

본 연구는 γ 만 0으로 두고 보강 경로의 출력은 0으로 두지 않음으로써 교착을 제거하였고, 이때 γ 가 0에서 벗어나 학습되는지 여부를 보강 정보의 유용성에 대한 증거로 해석한다.

멀티스케일 projector의 핵심 착안은 입력에 있다. OpenVLA의 시각 백본은 ViT의 끝에서 두 번째 블록 특징만 추출해 LLM에 전달하고 나머지 층(초기·중간 층의 미세한 공간 디테일)은 파이프라인에 도달조차 하지 않는다. 멀티스케일 projector는 식 (2)의 Enhance가 이 버려진 층들을 추가로 받도록 하되, 토큰 간 혼합 없이 토큰별로만 처리하여 “입력 확장”의 효과만을 격리한다.

2.3 데이터와 평가 지표

데이터는 Open X-Embodiment [7]에 포함된 jaco_play [8] (Kinova Jaco 로봇의 집기-놓기) 데이터를 사용하며, 학습 1,500 / 검증 256 (시드 0)으로 구성하고 OpenVLA의 변환·정규화를 동일하게 재현하였다. 행동 정확도는 예측과 정답 행동의 평균 절대 오차(이하 행동 L1 오차)로 측정한다. 시각의 존도는 입력 이미지를 다른 것으로 교체했을 때 예측이 변하는 정도 (vision_shift)로 측정한다. 공간 정보 전달량(spatial_shift)은, 정답 자세 거리는 크지만 그리퍼 상태는 유사한 — 즉 공간 변별이 실제로 필요한 — 검증 쌍을 골라, 지시 텍스트를 고정한 채 이미지만 교체했을 때 예측의 자세 차원이 변하는 양으로 정의한다. 값이 클수록 더 많은 공간 정보가 LLM에 도달함을 뜻한다. 행동 토큰을 argmax로 양자화하면 작은 이미지 변화가 빈을 넘지 못해 잡음이 크므로, 255개 행동 빈에 대한 softmax 기대값(연속형)을 주 지표로 사용한다. 온디바이스 효율은 추론 지연 시간과 최대 메모리로 측정하며, 측정은 단일 GPU에서 4-bit 양자화(fp16 연산)·SDPA 어텐션·배치 1의 자기회귀 디코딩 조건으로 수행하였다(peak VRAM 약 4.6 GB). 본 비교 실험은 학습률 $2e-4$, 3,000 step으로 수행하며, 데이터 스케일링(부록 A)은 LayerNorm이 없는 변종의 발산을 막기 위해 전 변종 공통으로 $2e-5$ 를 사용한다.

표 1. Projector별 정확도와 효율 비교(검증 256, 동일 조건). 지연은 LLM에 입력되는 토큰 수가 좌우하며(projector 자체 연산은 무시 가능) 256토큰 변종은 모두 기준선과 같은 약 331 ms, 64토큰 압축은 약 260 ms이다.

방식	행동 L1 오차	평균제곱오차	토큰 수	지연(ms)
동결 MLP(기준선)	0.0397	0.0247	256	331
Honeybee(압축)	0.0477	0.0213	64	260
자기어텐션	0.0534	0.0275	256	≈331
난수 MLP(정규화 없음)	0.2059	0.130	256	≈331
난수 MLP+LayerNorm	0.0481	—	256	≈331

3. 실험 결과 및 분석

3.1 온디바이스 효율: 토큰 압축의 이점

표 1는 주요 projector의 정확도와 효율을 동결 MLP 기준선과 비교한 것이다. Honeybee식 압축은 토큰을 256에서 64로 줄여 추론 지연을 331 ms에서 260 ms로 약 21% 단축하면서도 행동 정확도는 기준선에 근접한다(L1 0.0477 대 0.0397). 최대 메모리는 7B 규모의 LLM이 지배하므로 토큰 수에 거의 무관하게 약 4.6 GB로 유지되며, 따라서 압축의 실질적 이점은 속도이다. 즉 토큰 압축은 정확도를 크게 해치지 않으면서 온디바이스 추론을 가볍게 하는 실용적 수단이다. 같은 압축형이라도 교차어텐션은 정확도가 낮아, 효율 측면에서 정확도와 저비용을 함께 만족하는 것은 honeybee가 유일하다.




그림 2. 토큰 압축의 온디바이스 효과. 64토큰 압축은 256토큰 대비 추론을 약 21% 단축하며(331 → 260 ms), 메모리는 LLM이 지배해 거의 동일하다.

3.2 공간 혼합은 정확도에 기여하지 않는다

다음으로 projector 내부의 공간 혼합이 정확도를 높이는지 검증하였다. 난수에서 학습한 MLP는 L1 0.2059로 붕괴하지만, 여기에 LayerNorm만 추가하면 0.0481로 회복한다. 그러나 회복된 지점 위에 공간 혼합(자기어텐션)을 더해도 0.0534로 오히려 약간 악화될 뿐 이득이 없다(그림 3). 즉 난수 MLP의 붕괴 원인은 공간 정보의 부족이 아니라 정규화의 부재였으며, 공간 혼합은 정확도를 좌우하는 변수가 아니다.

이 현상의 원인은 세 가지로 설명된다. 본 과정은 사실상 평면 이동만을 요구해 공간 추론 수요가 낮고, 256개 시각 토큰의 공간 통합은 이미 LLM의 전체 자기어텐션이 수행하므로 projector에서 다시 섞는 것은 중복이며, 작은 데이터로 어텐션을 처음부터 학습하면 최적화 부담만 늘기 때문이다.

특히 “LLM이 공간 혼합을 수행한다”는 점은 인과적으로 확인된다. 추론 시 LLM 내부에서 시각 토큰끼리 주고받는 어텐션을 차단하면, 동결 MLP는 행동 오차가 86% 악화되어(0.041→0.075) 붕괴하는 반면, projector 단계에서 이미 토큰을 섞은 자기어텐션은 2%만 악화되어 사실상 영향을 받지 않는다(그림 4). 다만 이 면역은 우월성이 아니라, 자기어텐션이 이미 더 나쁜 지점




그림 3. 무엇이 난수 MLP를 회복시키는가. LayerNorm만으로 붕괴가 회복되며(0.2059 → 0.0481), 그 위에 공간 혼합을 더해도 이득이 없다(0.0481 → 0.0534).

표 2. 시각 의존도(vision_shift)와 선형 행동 복원(R^2). 두 지표가 서로 분리되어, 어느 쪽도 공간 혼합을 지지하지 않는다.

방식	시각 의존도 ($\uparrow$)	선형 복원 R^2 ($\uparrow$)
동결 MLP	0.128	-6.82
Honeybee	0.094	-2.15
자기어텐션	0.005	0.28
난수 MLP+LayerNorm	0.002	0.42

(0.080 대 0.041)에서 출발해 잃을 혼합이 없기 때문이다. 즉 동결 MLP는 공간 혼합을 전적으로 LLM에 의존하며, projector에서의 혼합은 그 일을 중복으로 수행할 뿐이다. 이는 공간 혼합 projector가 정확도 이득을 주지 못한 근본 원인을 인과적으로 뒷받침한다.

이를 더 확인하기 위해 두 가지 보조 실험을 수행하였다. 첫째, 입력 이미지를 다른 것으로 교체했을 때 예측이 변하는 정도(vision_shift)로 시각 의존도를 측정하였다. 둘째, projector 출력 토큰에서 정답 행동을 능선 회귀로 선형 복원한 결정계수(R^2)로 정보의 선형 접근성을 측정하였다(표 2). 두 지표는 서로 분리되는 양상을 보인다. 이미지를 가장 많이 활용하는 것은 사전학습된 동결 MLP이지만(vision_shift 0.128) 그 출력의 선형 행동 복원은 오히려 가장 낮은데($R^2 = -6.82$), 이는 동결 MLP가 행동 디코딩을 LLM에 맡기기 때문이다. 반대로 선형 복원이 높은 LayerNorm-MLP와 자기어텐션은 이미지를 거의 보지 않아(vision_shift 0.002, 0.005) 데이터의 행동 사전분포에 과적합된 것으로 해석된다. 결국 어느 축에서도 공간 혼합이 유리하지 않으며, 선형 접근성을 만드는 것조차 공간 혼합이 없는 LayerNorm-MLP(R^2 0.42)가 공간 혼합이 있는 자기어텐션(R^2 0.28)보다 높았다. 다만 이 탐침은 약한 대응 지표다. jaco_play에는 물체 위치 라벨이 없어 판독 대상으로 정답 행동을 사용하며, 동결 MLP의 음수 R^2 는 256-토큰 능선 회귀의 과적합도 일부 반영하므로 토큰 분산과 함께 해석해야 한다. 또한 학습 데이터를 500에서 30,000까지 늘려도 자기어텐션 등 대안 projector는 개선되다 약 0.073에서 정체하여 동결 MLP(0.0397)를 끝내 넘지 못했다(부록 A).

3.3 멀티스케일: LLM에 전달되는 공간 정보의 증가

공간 혼합이 지렛대가 아니라면 진짜 한계는 무엇인가. 본 연구는 그것이 projector의 입력, 즉 어떤 ViT 특징이 LLM에 도달하는가에 있다고 본다. 앞서 기울기 교착을 제거한 잔차 게이트(식 2)에 버려진 ViT 층을




그림 4. 인과 검증: 추론 시 LLM 내부의 시각 토큰 간 어텐션을 차단한 경우. 동결 MLP는 86% 악화되어 붕괴하지만(LLM이 공간 혼합을 대신 수행했음을 의미), projector에서 미리 섞은 자기어텐션은 2%만 악화되어 영향을 받지 않는다.

표 3. 멀티스케일 projector의 공간 정보 전달(동결 MLP 대비, 연속형 지표). 두 변종 모두 통계적으로 유의하게 증가하며, 게이트가 학습되어 교착이 해소된다.

지표	값
토큰별 멀티스케일 (7시드)	+30.8% ($p=0.0018$, 7/7)
스케일 간 어텐션 (5시드)	+34.1% ($p=0.019$, 5/5)
게이트 γ (학습 후)	$ \gamma \approx 0.06$ (전 시드 열림)

멀티스케일로 공급하자, 게이트 γ 는 모든 시드에서 0에서 벗어나 열렸다(부호는 시드마다 다르나 크기는 $|\gamma| \approx 0.06$ 로 일관). 이는 게이트가 닫히지 않고 학습되었음을 뜻하며(보강 정보가 일관되게 활용된다는 직접 증거는 아래의 전달량과 다운스트림 결과에 있다), 동시에 기존 보강형 변종의 “ $\gamma \rightarrow 0$ ”이 학습된 결정이 아니라 교착 버그였음을 확인해 준다.

표 3는 공간 정보 전달량의 변화를 정리한 것이다. 토큰별 멀티스케일은 동결 기준선 대비 spatial_shift를 평균 약 31% 증가시켰고(7개 시드, $p=0.0018$), 스케일 간 어텐션으로 층을 융합한 변종은 약 34% 증가시켰다(5개 시드, $p=0.019$). 두 경우 모두 시드 전부에서 양수였다. 초기 argmax 지표에서 나타났던 일부 음수는 행동 빈 양자화에 따른 잡음이었으며, 연속형 지표로 바꾸자 표준편차가 절반 가까이 줄며 신호가 일관되게 양수로 드러났다. 즉 버려졌던 층의 미세 공간 정보가 실제로 LLM에 더 많이 도달한다.

이 추가 정보는 행동 정확도에서도 효과를 보였으나, 그 효과는 상태에 따라 조건부였다(그림 5). 공간적으로 까다로운 상태에서는 스케일 간 어텐션 변종이 동결 기준선 대비 행동 오차를 4.8% 줄였다($p=0.025$; 단 hard·all·easy 세 부분집합에 대한 검정이므로 다중비교보정 시 경계적이다). 반면 공간 정보가 거의 무의미한 자명한 상태에서는 19% 악화되어($p=0.008$), 전체 평균으로는 두 효과가 상쇄되었다(약 5% 악화, 유의하지 않음). 이 분리는 추가된 공간 정보가 공간이 중요한 상황에서만 행동에 기여함을 보여주며, 멀티스케일이 전달한 정보가 무의미한 잡음이 아니라 실제 신호임을 뒷받침한다.

4. 결론

본 연구는 OpenVLA projector의 시각 정보 전달을 세 측면에서 재고하였다. 토큰 압축은 정확도를 유지하




그림 5. 멀티스케일의 행동 정확도 효과는 상태 조건부다. 공간이 중요한 상태에서는 오차가 4.8% 감소($p=0.025$) 하지만, 자명한 상태에서는 19% 증가($p=0.008$)하여 전체 평균으로는 상쇄된다. 음수가 개선을 뜻한다.

먼서 온디바이스 추론을 약 21% 단축하는 실용적 수단이며, projector 내부의 공간 혼합은 정확도에 기여하지 못하는데 난수 MLP 붕괴의 진짜 원인은 정규화 (LayerNorm)의 부재였다 — 256개 시각 토큰의 공간 통합은 이미 LLM이 수행하므로 projector에서의 추가 혼합은 중복이다. 진짜 지렛대는 어떤 특징이 LLM에 도달하는가에 있으며, 버려진 ViT 층을 함께 전달하는 멀티스케일 projector는 LLM에 도달하는 공간 정보를 유의하게 증가시킨다(토큰별 +31%, 스케일 간 어텐션 +34%). 이 효과는 행동에서도 공간이 중요한 상태에 한해 오차를 4.8% 줄이는 조건부 형태로 나타났으며(자명한 상태에서는 19% 악화되어 평균으로는 소폭 상쇄), LLM 내부 어텐션을 차단하면 동결 MLP가 86% 붕괴한다는 인과 실험은 공간 혼합을 LLM이 수행함을 직접 확인해 준다.

본 연구의 한계는 다음과 같다. 단일 로봇 데이터셋(jaco_play)·소수 시드에 기반하여 작은 MSE 차이는 잡음일 수 있다. spatial_shift와 vision_shift는 각각 자세 변화와 전체 이미지 교체에 대한 간접 대응 지표이며, 연속형 지표가 측정 잡음을 줄이지만 완전히 제거하지는 못한다. 또한 멀티스케일과 동결 MLP 모두 정답 공간 변화의 약 30%만 추종하는데, 이는 행동 정확도가 평균적으로 크게 움직이지 않는 이유와 일관된다. 끝으로 모든 평가는 오프라인 개루프 행동 L1 오차에 한하며, 페루프 돌아옴은 수행하지 않았다.

향후 과제는 다음과 같다. 단일 데이터셋·소수 시드라는 한계를 넘어 다양한 과제와 다중 시드로 일반성을 확인하고, 특히 공간 추론 수요가 큰 과제에서 멀티스케일 정보 전달이 행동 정확도로 전환되는지를 검증해야 한다. 종합하면 projector 설계의 핵심은 토큰 혼합이 아니라, 안정적 정규화·사전학습과 LLM에 전달되는 입력 특징의 폭에 있다.

부록 A: 데이터 스케일링

학습 데이터를 500에서 30,000까지($lr=2e-5$, $step \leq 30,000$) 늘린 행동 L1 오차를 표 4에 정리한다. 자기어텐션은 규모와 함께 개선되지만 약 0.073에서 정체하며, 어떤 대안도 본 범위에서 사전학습 동결 MLP(0.0397)를 넘지 못한다.

표 1와 표 4의 honeybee 수치 차이(0.0477 대 0.082)는 학습률 차이에서 비롯된 것으로 모순이 아니다. 이 보수적 학습률($2e-5$)은 LayerNorm을 갖춰 $2e-4$ 에서 안

정적인 honeybee를 과소학습시킨다. honeybee는 본 실험 학습률에서 0.0477까지 도달하나, 그 경우에도 동결 MLP(0.0397)에는 미치지 못한다.

표 4. 데이터 스케일링에 따른 행동 L1 오차(낮을수록 좋음).

변종	500	2,000	5,000	10,000	30,000
동결 MLP(불변)	0.040	0.040	0.040	0.040	0.040
자기어텐션	0.098	0.082	0.083	0.075	0.073
Honeybee	0.089	0.088	0.073	0.075	0.082
난수 MLP	0.072	0.105	0.076	0.081	0.090

참고문헌

- [1] M. J. Kim, K. Pertsch, S. Karamcheti, et al., “OpenVLA: An open-source vision-language-action model,” in Proc. Conf. Robot Learning (CoRL), 2024.
- [2] S. Karamcheti, S. Nair, A. Balakrishna, P. Liang, T. Kollar, and D. Sadigh, “Prismatic VLMs: Investigating the design space of visually-conditioned language models,” in Proc. Int. Conf. Machine Learning (ICML), 2024.
- [3] J. Cha, W. Kang, J. Mun, and B. Roh, “Honeybee: Locality-enhanced projector for multimodal LLM,” in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), pp. 13817–13827, 2024.
- [4] H. Liu, C. Li, Q. Wu, and Y. J. Lee, “Visual instruction tuning,” in Proc. Advances in Neural Information Processing Systems (NeurIPS), 2023.
- [5] M. Oquab, T. Darcet, T. Moutakanni, et al., “DINOv2: Learning robust visual features without supervision,” Trans. Machine Learning Research (TMLR), 2024.
- [6] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, “Sigmoid loss for language image pre-training,” in Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), 2023.
- [7] Open X-Embodiment Collaboration, “Open X-Embodiment: Robotic learning datasets and RT-X models,” in Proc. IEEE Int. Conf. Robotics and Automation (ICRA), 2024.
- [8] S. Dass, J. Yapeter, J. Zhang, et al., “CLVR Jaco Play dataset,” 2023. [Online]. Available: https://github.com/clvr-ai/clvr_jaco_play_dataset
- [9] G. Alain and Y. Bengio, “Understanding intermediate layers using linear classifier probes,” arXiv:1610.01644, 2016.